# Методология разметки аналитических материалов Альфа-Банка

## Навигация по документу


- 1. Цель, границы и согласованные принципы
- 2. Исходные документы и особенности корпуса
- 3. Объект разметки: документ, утверждение, связь
- 4. Классификация и критерии отбора
- 5. Правила атомарности, времени, чисел и авторства
- 6. Правила работы с PDF, графиками и таблицами
- 7. Пошаговый алгоритм для AI-агента
- 8. Контракт выходных данных (JSON)
- 9. Проверка, ошибки и показатели качества
- 10. Примеры размеченных утверждений
- 11. Готовая инструкция (промпт) для AI-агента
- Приложение А. Контрольные тестовые случаи


# 1. Цель, границы и согласованные принципы

### 1.1. Цель

Превратить один аналитический PDF в структурированный и трассируемый набор утверждений, на которые последующие компоненты смогут ссылаться при подготовке клиентских инсайтов. На входе — PDF и технические метаданные; на выходе — JSON с документом, утверждениями, внутридокументными связями и замечаниями о качестве.

### 1.2. Что входит в задачу

- Определить заголовок, подразделение-издателя, дату либо ее неизвестность, структуру и роли страниц.
- Извлечь все значимые факты, экспертные оценки, прогнозы, условные сценарии и рекомендации независимо от автора.
- Извлечь только относящиеся к основным тезисам подтверждающие показатели и аргументы.
- Разметить авторство, время, показатели, модальность, условия, доказательства и связи внутри документа.
- Проверить результат по оригинальному PDF; сформировать записи для ручного уточнения при неоднозначности.

### 1.3. Что не входит

- Нельзя добавлять собственные выводы о последствиях для конкретного бизнеса; отраслевой матчинг и бизнес-риски клиента относятся к следующему модулю.
- Не выполняется независимая проверка истинности экономических фактов во внешних источниках: только верность пересказа исходного документа.
- Не производится полная оцифровка каждого значения таблиц и каждой точки графика.
- Не выполняется объединение утверждений между разными отчетами или автоматическая замена устаревших прогнозов новыми.
- Не использовать другие LLM или внешний готовый AI-агент как основной компонент вопреки ограничениям кейса.

### 1.4. Согласованные принципиальные решения

| Вопрос | Принятое правило |
|---|---|
| Источник истины | Только содержание данного PDF; не дополнять знаниями модели и внешними новостями. |
| Приоритет | Факты, экспертные оценки и прогнозы равноправны; авторство не определяет важность. |
| Глубина | Самостоятельные значимые утверждения + связанные подтверждающие данные; без численного лимита на записи. |
| Графики | Точные числа лишь при ясной прямой подписи; не оценивать координаты визуально. |
| Подтверждение | У каждого claim и relation есть проверяемый элемент источника. |
| Статус | Автоматическая структурная проверка не приравнивается к экспертной проверке человеком. |

## 2. Исходные документы и особенности корпуса

Ниже приведены **девять фактически загруженных файлов** и проверенные характеристики файлов. В PDF отсутствует извлекаемый текстовый слой на первой странице каждого документа; для промышленной обработки понадобится отдельный этап распознавания текста и визуального анализа страниц.

| Файл (число страниц) | Темы и проверяемые особенности |
|---|---|
| Inflation_tracker_02.pdf (3) | 02.09.2026; инфляция, факты Росстата, экспертные оценки, недельный прогноз, графики, дисклеймер. |
| ALFA-consumption.pdf (4) | 05.08.2026; потребление, рынок труда, прогноз замедления спроса, графики. |
| ALFA-macro_stat1H26.pdf (5) | 31.07.2026; ВВП, промышленность, импорт, прогнозы нескольких показателей. |
| ALFA-7M26.pdf (4) | 07.09.2026; рынок труда, ограничение предложения, пересмотр макропрогнозов. |
| ALFA-Macro_Insights-Policy_Rate_11Sep.pdf (4) | 11.09.2026; решение ЦБ, позиция регулятора, оценка и прогноз Альфа-Банка. |
| Бонд_Бриф_14092026.pdf (5) | 14.09.2026; рынок облигаций, новости агентства «Эксперт РА», отдельная позиция Альфа-Банка. |
| FI_Strategy_3Q26_22072026.pdf (27) | 22.07.2026; долговой рынок, инвестиционные оценки и рекомендации; много графиков. |
| Gold_digest_August26.pdf (8) | Обзор рынка золота за август 2026; факторы цены, данные США и мировых центробанков. Точную дату выпуска нельзя выводить только из месяца в названии. |
| ALFA_Russian_Steels_1K21PreviewUpdate_15Apr2021.pdf (4) | 15.04.2021; исторический отраслевой анализ и прогнозы результатов металлургических компаний за 1К21. |

**Внимание к датам.** Период обзора (например, «август 2026») не равен дате публикации. Если день публикации не указан явно, он должен оставаться неизвестным; нельзя подставлять последний день месяца.

Отчет о российской стали относится к 2021 году: его прогнозы размечаются как исторические на дату выпуска, а не как актуальные на октябрь 2026 года. Аналитическая подборка кейса упоминает также

«Commodities performance»; отдельного файла с таким названием среди этих девяти загрузок нет — не следует выдумывать его содержание.

# 3. Единицы разметки и словарь

## 3.1. Три сущности

| Сущность | Что хранит |
|---|---|
| Document | Идентификатор и файл, название, издатель/подразделение, дату или ее отсутствие, страницы и роли страниц. |
| Claim | Одно самостоятельное аналитическое утверждение и его атрибуты: смысл, тип, важность, авторство, время, показатели, условия, подтверждение. |
| Relation | Документально подтвержденную направленную связь между двумя claim в пределах одного PDF. |

## 3.2. Определение атомарного утверждения

**Атомарное утверждение** — смысловой фрагмент с одним предметом и одной самостоятельной мыслью, которую можно подтвердить конкретным фрагментом PDF. Граница записи определяется смыслом, а не границей предложения или абзаца.

Пример: «ЦБ сохранил ставку 14%, а Альфа-Банк ожидает 14% на конец года» → два claim: наблюдавшееся решение ЦБ и прогноз аналитиков Альфа-Банка.

## 3.3. PRIMARY и SUPPORTING

Поле **is_primary = true** ставится самостоятельному значимому событию, аналитическому выводу, прогнозу, сценарию или рекомендации. **is_primary = false** — относящимся к ним подтверждающим данным или сравнительному контексту. Оно не означает низкую достоверность.

Один PRIMARY может одновременно быть аргументом для другого PRIMARY; его не нужно дублировать, достаточно добавить связь. Роль зависит от смысла в рамках конкретного отчета, а не от того, есть ли число или кто автор.

# 4. Типы утверждений и критерии отбора

## 4.1. Ровно один основной claim_type

| Тип | Определение | Диагностический вопрос |
|---|---|---|
| FACT | Сообщенный как состоявшийся факт, наблюдаемый показатель, официальное решение или факт пересмотра чужой оценки. | Автор сообщает «что произошло/сколько было»? |
| ASSESSMENT | Объяснение причин, оценка состояния рынка или значимости факторов без самостоятельного предписания. | Автор интерпретирует наблюдения? |
| FORECAST | Ожидаемое значение/направление на будущий для автора или еще не завершенный период. | Автор ожидает развитие по базовой траектории? |
| SCENARIO | Условная или возможная траектория при определенных предпосылках, не равная основному прогнозу. | Есть «если/может/при условии» и развитие событий? |
| RECOMMENDATION | Рекомендованное автором действие/выбор. | Автор советует сделать что-то? |

**Модальность** хранится отдельно: `observed`, `asserted`, `expected`, `possible`, `conditional`, `recommended`. Слово «может» нельзя переписывать как «обязательно приведет». Один тезис может содержать условие — не нужно автоматически дробить его на отдельный сценарий.

### 4.2. Правила включения PRIMARY

- Утверждение формулирует самостоятельный существенный вывод, заметное событие, изменение основного индикатора, прогноз, сценарий или рекомендацию в тематике отчета.
- Значимость подтверждена структурой и смыслом документа: резюме, заголовком, отдельным аналитическим фрагментом или повторяющимся предметом рассмотрения.
- Есть достаточно конкретный источник для воспроизведения исходного смысла. Если подтверждение невозможно прочитать надежно — фиксируем проблему, не выдаем за подтвержденный факт.
- Не обязательно быть выводом самого банка. Например, «ЦБ сохранил ставку 14%» тоже PRIMARY при условии центральности для отчета.

### 4.3. Правила включения SUPPORTING

- Показатель прямо используется автором для аргументации PRIMARY, его уточнения, ограничения или сравнения.
- Связь между записями документально обоснована; нельзя приписывать данным причинность только на основании экономической интуиции.
- Если показатель не связан с основной аналитикой, оставляем его в исходном PDF для последующего поиска, но не заносим отдельным claim.
- Повторяющееся утверждение внутри одного PDF не дублируем; сохраняем несколько evidence при необходимости.

### 4.4. Исключения

Не извлекать как аналитические тезисы рекламные блоки, контакты, юридические оговорки, названия осей сами по себе, машинно нераспознанные числа и значения графиков без явной подписи. Юридическую информацию можно отметить на уровне Document/page_roles; не смешивать ее с экономической аналитикой.

## 5. Атомарность, время, показатели и авторство

### 5.1. Когда разделять записи

- Разные основные предметы или показатели: ставка и инфляция — разные записи.
- Разные временные горизонты: конец 2026 года и конец 2027 года — две записи.
- Наблюдение и прогноз по одному показателю — разные записи.
- Разные владельцы утверждения: мнение ЦБ и собственная оценка банка — разные записи.
- Прогноз и факт его пересмотра: новый прогноз записываем как FORECAST с revision.explicit_revision; отдельный FACT о пересмотре создаем только при самостоятельной аналитической значимости, избегая дубля.

### 5.2. Когда не разделять

Не дробить один прогноз на бессмысленные фрагменты, если уточняющая оговорка является его обязательным условием. Не разрывать интервал, единицу и базу сравнения. Составное описание одного события можно оставить в одном claim, если все части необходимы для сохранения смысла.

### 5.3. Временная модель

| Поле | Правило |
|---|---|
| publication_date | Дата выхода PDF; если неизвестна — null, без догадки по названию файла/периоду обзора. |
| period.kind | observation / forecast / other / unspecified; определяется по состоянию на дату исходного документа, а не по текущей дате. |
| period.start, period.end | Нормализованные даты ISO, когда можно вывести их прямо из указанного периода; иначе null. |
| period.raw | Дословный период («4К26», «на конец года», «25–31 августа»). |
| revision | Явное обновление прогноза сохраняется, старое значение — только если указано. |

### 5.4. Числовая точность

- Хранить **value** числом лишь при явно указанном числовом значении; исходную формулировку сохранять в **value_text**.
- «Около нуля» → value = null, value_text = «на нулевых отметках», precision = approximate.
- «4,5–5%» → значение-диапазон, а не произвольная середина; precision = range.
- Дефляция 0,01% при аналитической нормализации инфляции допускает value = −0.01%; обязательно сохранить исходное словесное значение, чтобы знак можно было проверить.
- Не путать проценты с процентными пунктами, г/г с м/м, недельную и годовую инфляцию, ставку среднегодовую и на конец года, номинальные и реальные показатели.
- Если конкретная дата, денежная единица или база сравнения не указаны — сохранять null / «не указано», не выводить из общеэкономических знаний.

### 5.5. Авторство и источник

**publisher** — выпустившая организация (Альфа-Банк); **department** — указанное на документе подразделение; **statement_owner** — источник утверждения (ЦБ, Эксперт РА, аналитики Альфа-Банка и др.); **data_source** — источник данных, если он обозначен. Не считать автором тезиса банк только потому, что он его процитировал.

Например, в «Бонд Брифе» (стр. 2) рейтинговое действие агентства «Эксперт РА» и раздел «Наше мнение» — разные claims с разным statement_owner. В отчете по ключевой ставке (стр. 1) решение ЦБ и прогноз Альфа-Банка также принадлежат разным авторам.

## 6. Работа с PDF, таблицами и графиками

### 6.1. Этап распознавания

Все девять отчетов представляют собой преимущественно страницы-изображения без извлекаемого текстового слоя. Система должна последовательно читать страницу как изображение, извлекать структуру блоков/таблиц/подписей, затем сопоставлять результат с оригиналом. Для распознавания может применяться разрешенная кейсом мультимодальная LLM либо отдельный OCR; AI-модель не должна заменять визуальную проверку спорных чисел.

### 6.2. Роли страниц

| Роль | Что означает |
|---|---|
| analytical | Содержит аналитический текст/выводы/показатели. |

| | |
|---|---|
| supporting_visuals | Содержит таблицы или графики, поддерживающие аналитические утверждения. |
| metadata | Титульные сведения, дата, название, подразделение, структура. |
| legal | Дисклеймер, ограничения использования, юридические пояснения. |

Роли не взаимоисключающие: титульная страница часто сразу содержит аналитику. Страница 3 отчета об инфляции в основном юридическая и не порождает claims.

### 6.3. Консервативное извлечение графиков

- Точное число из графика разрешено, только если оно явно и однозначно подписано около точки, столбца или внутри таблицы.
- Не делать численных выводов по высоте линии, расстоянию от делений оси, масштабу или цвету без четкой подписи.
- Тренд из графика допускается как claim, только если соответствующий качественный вывод сформулирован автором или однозначно написан в пояснении; иначе график — evidence/context.
- В evidence.source_kind = chart указывать страницу и идентификатор/заголовок рисунка; excerpt может быть null, если на графике нет цитируемого текста.
- При плохом качестве подписи оставлять поле неопределенным и выдавать issues/needs_review.

### 6.4. Таблицы

Из таблиц извлекать только явно читаемые ячейки, связанные с выбранными claims. Для каждой числовой записи фиксировать заголовок таблицы, название строки, колонки, единицу и период. Если шапка или единица плохо видна, число не нормализовать, а отправлять на проверку.

### 6.5. Подтверждение источником

Для каждого claim и relation обязательна **проверяемая опора**: имя файла/ID документа, номер страницы (1-based), тип объекта (text/table/chart), местоположение (раздел, заголовок, «рис. 3», «табл. 1») и, для текста, дословная короткая цитата. Нельзя генерировать фиктивные цитаты из пересказа. Если опору точно восстановить нельзя — пометить запись на проверку.

## 7. Пошаговый алгоритм для AI-агента

Ниже — обязательный порядок, а не рекомендация выбирать отдельные понравившиеся действия. При больших файлах обработка выполняется блоками, но завершается проверкой всего документа.

**01. Инвентаризация.** Получить PDF и page_count; составить карту страниц, дату (если известна), заголовок, издателя, подразделение, перечень разделов; проверить, не скрывает ли титульный лист аналитический текст.

**02. Распознавание.** Прочитать страницы по отдельности; сопоставить заголовки, сноски, легенды и ячейки таблиц с изображениями; список нечитаемых мест добавить в issues.

**03. Кандидаты PRIMARY.** Для каждого смыслового раздела составить все значимые самостоятельные факты, оценки, прогнозы, сценарии и рекомендации без авторского приоритета.

**04. Атомарность и дедупликация.** Разделить разные показатели/авторов/горизонты; объединить повторы идентичного утверждения внутри PDF, сохранив evidence по нескольким местам.

**05. Поддержка.** Для каждого PRIMARY найти значимые связанные показатели, причины, оговорки и сравнения. Постороннюю статистику не размечать.

**06. Атрибуты.** Указать тип, роль, statement_owner, data_source, модальность, период, численные метрики, условия, признак пересмотра и источники.

**07. Внутридокументные связи.** Создать только обоснованные SUPPORTS / EXPLAINS / CONTEXT_FOR / QUALIFIES. Для каждой связи сохранить направление и evidence.

**08. Самопроверка.** Повторно сверить числа, знаки, период, базу сравнения, авторство, дословные цитаты и неизвлеченные значимые фрагменты; отметить спорные случаи.

**09. Формирование результата.** Сформировать JSON строго по утвержденному контракту, без Markdown-вступления, без новых фактов и без пометки human_verified.

**10. Валидация и эскалация.** Выполнить структурную и содержательную проверку, устранить проверяемые ошибки; неясности передать человеку через issues и requires_clarification.

### 7.1. Многошаговость и экономия токенов

Разделить роли технических компонентов: парсер/визуальное извлечение → кандидатные утверждения → нормализация/связи → независимая проверка. Агент сохраняет результаты промежуточных шагов, выполняет повторный поиск при недостаточности доказательства и журналирует действия. Для этого достаточно одного агента с инструментами: число агентов само по себе не влияет на оценку кейса.

Рекомендуется кешировать распознанные блоки и результат извлечения по хешу документа. Однако экономия ресурсов не должна приводить к потере утверждений; ограничения бюджета LLM нужно контролировать отдельно.

## 8. Контракт выходных данных

### 8.1. Структура ответа

Минимальная структура — объект JSON с полями `schema_version`, `document`, `claims`, `relations`, `issues`. В ранее подготовленной версии v0.6 поля `document`, `claims`, `relations` уже определены. Ниже — согласованная схема с **уточнением для неизвестных дат**; разработчикам необходимо синхронно обновить валидатор и JSON Schema перед реальным запуском.

> **Исправление против домыслов.** Старая схема v0.6 требовала непустую дату публикации. Для отчетов с неизвестным точным днем это принуждает модель придумывать дату. В предлагаемом контракте v1.0 publication_date может быть null с сохранением publication_date_text.

### 8.2. Поля Document

| Поле | Тип / обязательность | Правило |
|---|---|---|
| document_id / filename | string / обязательно | Устойчивый ID и точное имя файла. |
| title / publisher | string / обязательно | Название и издатель как в PDF. |
| department | string\|null / обязательно | Только явно указанное подразделение. |
| publication_date | ISO date\|null / обязательно | Если неизвестна — null. |
| publication_date_text | string\|null / обязательно | Например, «август 2026» — не выдавать за точный день публикации. |
| page_count | integer / обязательно | Фактическое число страниц. |
| page_roles | array / обязательно | Каждая страница, роли из 4 согласованных категорий. |

### 8.3. Поля Claim

| Поле | Тип / обязательность | Правило |
|---|---|---|
| claim_id | string / обязательно | Уникален внутри документа. |
| is_primary | boolean / обязательно | true для самостоятельного тезиса; false для связанного контекста. |
| claim_type | enum / обязательно | FACT / ASSESSMENT / FORECAST / SCENARIO / RECOMMENDATION. |
| statement | string / обязательно | Кратко и точно, с сохранением смысловых оговорок. |
| subject | string / обязательно | Предмет/индикатор, по возможности из контролируемого справочника. |
| attribution | object / обязательно | statement_owner и data_source; неизвестное допускает null. |
| modality | enum / обязательно | observed / asserted / expected / possible / conditional / recommended. |
| period | object / обязательно | kind: observation/forecast/other/unspecified; start,end: ISO\|null; raw: string\|null. |
| metrics | array / обязательно | 0+ объектов indicator, value, value_text, unit, comparison_basis, precision. |
| conditions | string[] / обязательно | Только указанные автором существенные оговорки. |
| evidence | array / обязательно | Минимум один источник: page, source_kind, locator, excerpt. |
| revision | object / обязательно | explicit_revision + source_phrase; прошлое значение только если оно раскрыто. |
| review_status | enum / обязательно | pending_human_review / requires_clarification / human_verified; последнее ставит только человек. |

### 8.4. Поля Relation

| Поле | Тип / обязательность | Правило |
|---|---|---|
| from_claim_id / to_claim_id | string / обязательно | Существующие claim_id, разные; направление зафиксировано. |
| relation_type | enum / обязательно | SUPPORTS / EXPLAINS / CONTEXT_FOR / QUALIFIES. |
| evidence | array / обязательно | Минимум одна ссылка на аргумент связи в самом PDF. |

### 8.5. Поля Issue

Список `issues` содержит элементы `{page, kind, description, related_claim_id}`. Он используется при нечитаемом графике, неподтверждаемой цитате, спорном авторстве, неполной дате и других сомнениях. Наличие issues не означает невалидный JSON. При невозможности извлечь хоть одно утверждение допускается пустой массив claims с issue, а не придуманный тезис.

### 8.6. Рекомендуемый пример JSON (сокращенный)

```
{
  "schema_version": "1.0",
  "document": {
    "document_id": "INFLATION_20260902",
    "filename": "Inflation_tracker_02.pdf",
```

```
    "title": "Инфляция 25–31 августа: основные выводы",
    "publisher": "Альфа-Банк",
    "department": "Центр макроэкономического анализа",
    "publication_date": "2026-09-02",
    "publication_date_text": "2 сентября 2026 года",
    "page_count": 3,
    "page_roles": [
      {"page": 1, "roles": ["analytical", "supporting_visuals", "metadata"]},
      {"page": 2, "roles": ["supporting_visuals"]},
      {"page": 3, "roles": ["legal"]}
    ]
  },
  "claims": [{
    "claim_id": "INF-P01",
    "is_primary": true,
    "claim_type": "FACT",
    "statement": "За 25–31 августа 2026 года Росстат зафиксировал недельную дефляцию 0,01%.",
    "subject": "weekly_consumer_price_change",
    "attribution": {"statement_owner": "Росстат", "data_source": "Росстат"},
    "modality": "observed",
    "period": {"kind": "observation", "start": "2026-08-25",
               "end": "2026-08-31", "raw": "25.08–31.08"},
    "metrics": [{"indicator": "weekly_inflation", "value": -0.01,
                 "value_text": "дефляция на 0,01% н/н", "unit": "% н/н",
                 "comparison_basis": "к предыдущей неделе",
                 "precision": "exact_as_written"}],
    "conditions": [],
    "evidence": [{"page": 1, "source_kind": "text",
                  "locator": "Что говорят данные Росстата, пункт 1",
                  "excerpt": "Росстат зафиксировал дефляцию на 0,01% н/н"}],
    "revision": {"explicit_revision": false, "source_phrase": null},
    "review_status": "pending_human_review"
  }],
  "relations": [],
  "issues": []
}
```


Этот JSON иллюстрирует структуру, но **не является полной разметкой** отчета и не доказывает качество автоматической модели. Для промышленного запуска необходима формальная JSON Schema v1.0, синхронизированная с указанными полями.

## 9. Валидация, ручной аудит и оценка качества

### 9.1. Проверка в четыре слоя

| Уровень | Что проверяем |
|---|---|
| 1. Формат | Строгий JSON, допустимые enum, обязательные поля, корректные даты и типы значений. |
| 2. Ссылочная целостность | Уникальные claim_id; все relations указывают на существующие claim; страницы от 1 до page_count. |
| 3. Соответствие PDF | Цитаты реально существуют; числа и знаки точны; графики подписаны; источники, авторство и периоды верны. |
| 4. Семантика | Полнота, атомарность, отсутствие дублей, лишних заявлений, выдуманной причинности, укрепления модальности. |

### 9.2. Блокирующие ошибки

- Вымышленная цитата, несуществующий источник, ссылка на неправильную страницу.
- Искаженное число, знак, единица, горизонт прогноза, база сравнения или приписанное не тому субъекту мнение.

- Прогноз представлен как уже состоявшийся факт или возможность превращена в определенность.
- Необоснованная связь с новым экономическим смыслом, которой не было в исходном документе.
- AI присвоил себе статус human_verified без фактической проверки человеком.

### 9.3. Метрики эксперимента с AI

- PRIMARY recall: TP / (TP + FN), полнота основных утверждений.
- PRIMARY precision: TP / (TP + FP), точность извлеченных основных утверждений.
- Отдельные precision/recall для SUPPORTING и для связей.
- Attribute correctness: тип, авторство, временной горизонт, число, единица, модальность, условия — отдельно по совпавшим утверждениям.
- Evidence accuracy: доля утверждений с корректной привязкой к исходной странице/фрагменту.
- Unsupported claims и duplicate rate: отдельно, даже если суммарный precision высокий.
- JSON validation: pass/fail как технический тест, не как оценка достоверности.

Сопоставлять автоматический ответ с эталоном **по смыслу**, а не по совпадению ID или буквальной формулировке. Один модельный claim нельзя несколько раз засчитать как TP. Пороговые значения (например, 90% или 95%) пока не задавать без эмпирического теста.

### 9.4. Список категорий ошибок

`SOURCE_RECOGNITION`, `OMISSION`, `HALLUCINATION`, `ATOMIZATION`, `TYPE`, `ATTRIBUTION`, `TEMPORAL`, `NUMERIC`, `MODALITY`, `EVIDENCE`, `RELATION`, `DUPLICATE`. Для каждого замечания фиксировать claim_id, источник, исправление и причину.

### 9.5. Статус эталона

Черновая разметка отчета об инфляции из версии 0.6 содержит 20 утверждений (12 PRIMARY + 8 SUPPORTING) и 11 связей. Это **предварительный набор**, все записи по умолчанию ожидают человеческой проверки. Соответствие структуре JSON не делает его утвержденным эталоном.

## 10. Проверенные примеры и типовые ловушки

| Фрагмент источника | Правильная разметка и ловушка |
|---|---|
| «Инфляция 25–31 августа», стр. 1 | FACT: недельная дефляция 0,01%; value = −0.01 при нормализации инфляции, value_text сохраняет слово «дефляция». Не путать с инфляцией +0,01% прошлой недели. |
| «Ключевая ставка ЦБ РФ», 11.09, стр. 1 | Отдельно FACT: ЦБ оставил 14%; отдельно FORECAST: Альфа-Банк ожидает 14% на конец 2026. Не смешивать авторство и временной период. |
| «Потребление на пике», 05.08, стр. 1 | FORECAST: рост потребления «на нулевых отметках» в 4К26; value = null, value_text и приблизительность сохранены. |
| «Обзор рынка золота», стр. 3 | FACT: августовская доходность золота +9,7%, явно подписана на графике; source_kind = chart. Неподписанные точки не оцифровывать. |
| «Бонд Бриф», 14.09, стр. 2 | FACT: рейтинговое действие «Эксперт РА»; отдельно ASSESSMENT Альфа-Банка в «Наше мнение». Не приписывать мнение агентства банку. |
| «Макростатистика 1П26», стр. 1 | FORECAST с отдельным горизонтом для каждого показателя: ВВП, безработица, инфляция, курс. Не объединять значения в одно утверждение. |
| «Макростатистика 7М26», стр. 1 | ASSESSMENT о недостаточном охлаждении рынка труда; выделить supporting по динамике заработных плат и вакансий там, где прямо связаны с выводом. |
| «Тактический взгляд 3К26», стр. 3 | RECOMMENDATION по облигационному портфелю отделять от FORECAST доходностей и ASSESSMENT рынка. |

| | |
|---|---|
| «Российская сталь», 15.04.2021, стр. 1 | Исторические FORECAST на результаты 1К21. Не отмечать как текущую позицию банка. |

## 11. Готовый промпт для AI-агента

Ниже — текст инструкции, предназначенный для системного сообщения / основного шага извлечения. Перед запуском подставить входной PDF, стабильный ID документа и согласованный контракт JSON версии 1.0. При делении документа на страницы модель должна получить карту разделов и итоговый контекст всего PDF.

**РОЛЬ. Ты — AI-компонент строгой разметки аналитических PDF Альфа-Банка. Твоя задача — извлечь содержание исходного отчета, а не создавать новую аналитику.**

**ИСТОЧНИК. Используй только переданный PDF и приложенные машинные метаданные. Не применяй внешние новости, знания о компаниях и неподтвержденные догадки.**

**ЦЕЛЬ. Верни JSON с document, claims, relations, issues по утвержденной схеме. Сохраняй все значимые самостоятельные факты, оценки, прогнозы, сценарии и рекомендации; независимо от того, кто их автор. Добавляй только напрямую относящиеся подтверждающие показатели и аргументы. Лимит на число записей не задан.**

**ПОРЯДОК:**
1) Пройди весь документ, установи заголовок, дату или ее отсутствие, подразделение и роли страниц.
2) Найди основные аналитические утверждения по смысловым блокам, включая самостоятельные важные факты.
3) Раздели разные показатели, периоды, авторов, факты и прогнозы на атомарные claim; не разрывай условия одного тезиса.
4) Убери точные дубликаты в пределах PDF, сохрани все существенные места подтверждения.
5) Для каждого основного утверждения найди только прямо связанные факты, числа и аргументы.
6) Присвой claim_type: FACT, ASSESSMENT, FORECAST, SCENARIO либо RECOMMENDATION; модальность размечай отдельно.
7) Укажи statement_owner отдельно от издателя и data_source; если автор не установлен — оставь неизвестным, не угадывай.
8) Сохраняй значения, единицы, знак, базу сравнения, дату и горизонт, приблизительность, условия, историю явно указанного пересмотра.
9) Из графика извлекай точное число ТОЛЬКО при явной читаемой подписи. Не вычисляй значения по точкам/осям. Для неоднозначностей создай issue.
10) Для каждого claim и relation приложи страницу и конкретное место в документе: дословную короткую цитату, номер таблицы либо графика. Не выдумывай цитаты.
11) Создавай только подтвержденные внутридокументные relations: SUPPORTS, EXPLAINS, CONTEXT_FOR, QUALIFIES.
12) Повторно сверь все извлеченные записи с исходными страницами. Если число, авторство или цитата сомнительны — requires_clarification, не human_verified.

**ЗАПРЕЩЕНО. Интерпретировать влияние на конкретные компании; делать выводы от себя; искать данные вне PDF; считать период обзора точной датой выпуска; считать прошлый прогноз текущим; придумывать предыдущее значение пересмотренного прогноза; присваивать human_verified автоматически.**

**ВЫХОД. Только валидный JSON по согласованному контракту. Не добавляй вводных фраз, Markdown, пояснений после JSON. Если документ плохо читается, верни issues и только надежно подтвержденные claims.**

## Приложение А. Контрольные тестовые случаи

Тесты формируют базовую проверку спецификации. Результат «ожидается» — критерий будущего запуска, а не заявление, что разрешенная LLM уже прошла тест.

| № | Вход / пограничный случай | Ожидаемый результат |
|---|---|---|
| 1 | «Ставка сохранена 14%; банк ожидает 14% на конец года». | Два claim: FACT и FORECAST; авторы и периоды раздельны. |
| 2 | «Рост на нулевых отметках». | Approximate, value=null; не точные 0,0. |

| | | |
|---|---|---|
| 3 | График без подписанных точек. | Не извлекать точных значений; locator графика, issue при необходимости. |
| 4 | График с явно подписанным +9,7%. | Точное число с source_kind=chart и ссылкой на рисунок. |
| 5 | Слова «может», «при условии», «вероятно». | Не усиливать модальность; сохранить условия. |
| 6 | Исторический прогноз компании за 1К21. | FORECAST на дату документа 2021, не текущий факт. |
| 7 | Рейтинг «Эксперт РА» + раздел «Наше мнение». | Раздельное авторство; нет подмены выводов. |
| 8 | Два одинаковых утверждения на страницах 1 и 3. | Один claim с несколькими evidence. |
| 9 | Сравнение с прошлой неделей. | CONTEXT_FOR, не автоматическое SUPPORTS. |
| 10 | Взаимосвязь кажется экономически логичной, но не указана. | Не создавать Relation. |
| 11 | Период «август 2026» без дня публикации. | publication_date=null; текст периода сохранен. |
| 12 | Нечитаемая строка таблицы / нет ясной единицы. | Issue и запрос на проверку, не выдумывать значение. |
| 13 | Юридический дисклеймер с предупреждениями. | page_roles legal; не создавать макроэкономические claim. |
| 14 | Предыдущий прогноз пересмотрен без старого числа. | revision.explicit_revision=true; старое значение не угадывать. |
| 15 | Несколько горизонтов одного показателя. | Раздельные claim для разных горизонтов. |